



UNIVERSIDAD POLITÉCNICA METROPOLITANA DE HIDALGO

PROGRAMA EDUCATIVO DE MAESTRÍA EN INTELIGENCIA ARTIFICIAL

“ESTADÍSTICA APLICADA”

Reporte: Tarea 9

*Flores García Katherine
Itzel
(253220100)
Morales Hernández
Emmanuel
(253220003)*

2 de diciembre de 2025

Índice

1. Objetivo	3
2. Introducción	3
3. Planeamiento del análisis	3
3.1. Parte I	3
3.1.1. Tratamiento de nulos	4
3.1.2. Análisis Univariado	4
3.1.3. Limpieza y transformación de datos	19
3.1.4. Codificación y estandarización	21
3.2. Parte II	22
3.2.1. Método: Correlación Canónica	22
3.2.2. Justificación	25
3.2.3. Utilidad del método “Correlación Canónica” en el dataset	25
3.2.4. Análisis de los resultados	26
4. Conclusión	28
Referencias	29

Índice de figuras

1. Visualización de category_id	6
2. Visualización de view_count	7
3. Visualización de like_count	7
4. Visualización de comment_count	8
5. Visualización de favorite_count	9
6. Visualización de engagement_rate	10
7. Visualización de likes_to_views_ratio	10
8. Visualización de comments_to_views_ratio	11
9. Visualización de duration_seconds	12
10. Visualización de video_age_days	13
11. Distribución de channel_title	15
12. Distribución de published_at	15
13. Distribución de channel_title	18
14. Distribución de definition	19

1. Objetivo

El objetivo de este trabajo es analizar de manera multivariada el desempeño de videos de YouTube a partir de un conjunto de variables de escala (vistas, “me gusta”, comentarios, duración y antigüedad) y de eficiencia o engagement relativo (tasa de interacción y razones por vista), aplicando técnicas de limpieza, transformación y preprocesamiento de datos, así como el método de correlación canónica para estudiar la relación conjunta entre ambos bloques de variables. Este objetivo incluye la implementación de procedimientos para atenuar la influencia de valores atípicos, corregir el sesgo de las distribuciones, codificar adecuadamente las variables categóricas, estandarizar las variables numéricas y, finalmente, extraer dimensiones latentes que resuman la asociación entre el tamaño de la audiencia y la intensidad relativa de interacción de los usuarios.

2. Introducción

El uso de las plataformas digitales de video ha generado grandes volúmenes de datos sobre el comportamiento de la audiencia, incluyendo métricas como vistas, “me gusta”, comentarios, duración del contenido y diferentes indicadores de engagement. El análisis adecuado de estos datos requiere un preprocesamiento cuidadoso que contemple la presencia de distribuciones altamente asimétricas, valores atípicos extremos y la combinación de variables numéricas y categóricas en un mismo modelo. En este contexto, la aplicación de técnicas de limpieza y transformación, como la winsorización basada en puntuaciones tipificadas y las transformaciones de potencia, resulta fundamental para mejorar la estabilidad estadística de las estimaciones y aproximar mejor los supuestos de normalidad y homocedasticidad requeridos por numerosos métodos multivariantes.

Una vez preparado el conjunto de datos, surge el interés por comprender la relación conjunta entre dos bloques conceptualmente diferenciados: por un lado, las variables que describen la escala o alcance del video, y por otro, las que miden la eficiencia relativa de la interacción de la audiencia. La correlación canónica se presenta como una herramienta apropiada para este propósito, ya que permite encontrar combinaciones lineales de cada bloque que maximizan la correlación entre sí y revelan dimensiones latentes de asociación entre escala y engagement. Este enfoque proporciona una visión más rica que el análisis bivariado simple, al capturar patrones de relación que emergen únicamente cuando se consideran simultáneamente múltiples variables en cada conjunto.

El código implementado durante esta investigación se encuentra disponible en el siguiente enlace: [Link de Google Colab](#).

3. Planeamiento del análisis

3.1. Parte I

Para la elaboración de esta actividad, se decidió escoger el dataset *YouTube Analytics Data* desde la página de Kaggle [1]. Ya que (dar motivos de porque escoger este dataset o que tiene de interesante analizarlo).

El dataset está conformado por 537 filas y 16 columnas, de las cuales cuenta con la siguiente información:

Nombre de la columna	Tipo de dato	Descripción
Title	Catégorica nominal	Título del video tal como aparece en YouTube.
channel_title	Catégorica nominal	Nombre del canal que publicó el video.
published_at	Catégorica ordinal	Fecha y hora de publicación del video en la plataforma.
category_id	Catégorica nominal (codificada numéricamente)	Identificador numérico de la categoría de contenido definida por YouTube.
view_count	Numérica discreta	Número total de visualizaciones acumuladas del video.
like_count	Numérica discreta	Número total de “me gusta” que ha recibido el video.
comment_count	Numérica discreta	Número total de comentarios publicados en el video.
favorite_count	Numérica discreta	Número de veces que el video fue marcado como favorito.
duration	Catégorica nominal	Duración del video en formato ISO 8601 (por ejemplo, PT3M20S).
definition	Catégorica ordinal	Calidad de resolución del video (por ejemplo, sd, hd).
caption	Catégorica binaria	Indica si el video tiene subtítulos disponibles (TRUE/FALSE).
engagement_rate	Numérica continua	Tasa de interacción global del video respecto a sus visualizaciones.
likes_to_views_ratio	Numérica continua	Relación entre el número de “me gusta” y el número de visualizaciones.
comments_to_views_ratio	Numérica continua	Relación entre el número de comentarios y el número de visualizaciones.
duration_seconds	Numérica discreta	Duración del video expresada en segundos.
video_age_days	Numérica discreta	Antigüedad del video en días respecto a la fecha de extracción del dataset.

Cuadro 1: Diccionario de datos de *youtube_recommendation_dataset*

El *Cuadro 1*, la pueden visualizar con el siguiente comando que se presenta en el *Listing 1*.

Listing 1: Ejecución `df.info()`

```
1 display(df.info())
```

3.1.1. Tratamiento de nulos

3.1.2. Análisis Univariado

El análisis univariado constituye el primer nivel de exploración en un conjunto de datos, porque se centra en estudiar de manera aislada la distribución de cada variable antes de analizar relaciones entre ellas. Su finalidad principal es describir el comportamiento de una sola variable mediante medidas numéricas (como tendencia central y dispersión) y representaciones gráficas (como histogramas, diagramas de caja o tablas de frecuencias), lo que permite identificar patrones básicos, valores extremos, posibles errores de registro y la forma general de la distribución [2].

Este tipo de análisis es crucial dentro de la fase de análisis exploratorio de datos, ya que proporciona una base sólida para decisiones posteriores de limpieza, transformación y modelado estadístico. Sin una comprensión adecuada de cada variable por separado (por ejemplo, su rango, asimetría, concentración de valores o presencia de clases dominantes), cualquier análisis bivariado o multivariado se construye sobre cimientos frágiles y corre el riesgo de producir resultados engañosos.

Numérico En esta sección se analizan las variables numéricas del conjunto de datos de recomendaciones de YouTube, las cuales son: `category_id`, `view_count`, `like_count`, `comment_count`, `favorite_count`, `engagement_rate`, `likes_to_views_ratio`, `comments_to_views_ratio`, `duration_seconds` y `video_age_days`. El código del cuaderno calcula para cada una el resumen descriptivo clásico (count, mean, std, min, cuartiles y max) y genera gráficos como histogramas y diagramas de caja, con el objetivo de visualizar la forma de la distribución, la dispersión y la presencia de valores atípicos. La salida generada por este comando se presenta en el Listing 2.

Listing 2: Ejecución Análisis Univariado (Numérica)

```
1 # Selección de columnas Numéricas
2 col_num = df.select_dtypes(include=["number"]).columns.tolist()
3
4 for col in col_num:
5     print(f"\n==== Variable numérica: {col} ====")
6     print(df[col].describe())
7     print("Nulos:", df[col].isna().sum())
8
9     # Histograma + densidad
10    plt.figure(figsize=(8, 4))
11    sns.histplot(data=df, x=col, kde=True)
12    plt.title(f"Histograma y densidad de {col}")
13    plt.xlabel(col)
14    plt.ylabel("Frecuencia")
15    plt.tight_layout()
16    plt.show()
17
18    # Boxplot para outliers
19    plt.figure(figsize=(6, 3))
20    sns.boxplot(x=df[col])
21    plt.title(f"Boxplot de {col}")
22    plt.xlabel(col)
23    plt.tight_layout()
24    plt.show()
```


A partir de estos resultados se obtiene una visión detallada del comportamiento de las métricas clave de popularidad, interacción y características temporales de los videos.

- **category_id**. Como se muestra la *Figura 1* esta variable, aunque conceptualmente categórica, se resume numéricamente con 537 observaciones, un rango entre 1 y 28, y una media aproximada de 22.46, con mediana 24 y cuartiles en 20 y 27. El hecho de que tanto el percentil 25 como el 75 se sitúen en valores relativamente altos indica que la mayoría de los videos se concentran en un subconjunto de categorías de YouTube asociadas a identificadores elevados, mientras que categorías con identificadores bajos aparecen con menos frecuencia en la muestra.


```

===== Variable numérica: category_id =====
count      537.000000
mean       22.456238
std        5.854776
min        1.000000
25%       20.000000
50%       24.000000
75%       27.000000
max       28.000000
Name: category_id, dtype: float64
Nulos: 0

```



(a) Histograma y Densidad



(b) Boxplot

Figura 1: Visualización de category_id

- **view_count.** Como se muestra la *Figura 2* el conteo de visualizaciones presenta 537 registros con una media cercana a 2.15×10^7 vistas, una mediana de aproximadamente 6.39 millones y un máximo que alcanza cerca de 369.7 millones de visualizaciones. La distancia entre la mediana y el máximo, junto con una desviación estándar de unos 4.02×10^7 y un tercer cuartil cercano a 22.7 millones, revela una distribución fuertemente asimétrica a la derecha: pocos videos acumulan un número extraordinario de vistas, mientras que la mayoría se concentra en un rango considerablemente más bajo; los histogramas y diagramas de caja refuerzan la presencia de una cola larga hacia valores muy altos.

```

===== Variable numérica: view_count =====
count      5.370000e+02
mean       2.145752e+07
std        4.015200e+07
min        0.000000e+00
25%       2.676921e+06
50%       6.385911e+06
75%       2.270604e+07
max       3.697310e+08
Name: view_count, dtype: float64
Nulos: 0

```




Figura 2: Visualización de view_count

- **like_count.** Como se muestra la *Figura 3* el número de “me gusta” muestra una media aproximada de 433,604, una mediana de cerca de 155,055 y un máximo superior a 10.8 millones, con una desviación estándar del orden de 8.39×10^5 . Esta combinación de valores indica que la interacción mediante likes también está muy concentrada: la mayor parte de los videos se sitúa por debajo de medio millón de likes, pero existe un subconjunto reducido con cifras extraordinariamente altas que estiran la distribución; en los gráficos de caja, estos casos se manifiestan como puntos atípicos claramente separados del resto.

```
===== Variable numérica: like_count =====
count      5.370000e+02
mean       4.336044e+05
std        8.386711e+05
min        0.000000e+00
25%        5.559100e+04
50%        1.550550e+05
75%        4.631890e+05
max        1.087934e+07
Name: like_count, dtype: float64
Nulos: 0
```




Figura 3: Visualización de like_count

- **comment_count.** Como se muestra la *Figura 4* en el conteo de comentarios se observa una media en torno a 7,126, una mediana de 2,354, un tercer cuartil de 5,925 y un máximo que supera los 810,000 comentarios, acompañado de una desviación estándar superior a 36,000. La estructura de estos valores muestra nuevamente una distribución altamente asimétrica a la derecha: la mayoría de los videos concentra solo unos miles de comentarios, mientras que unos pocos generan debates masivos, lo que tiene implicaciones importantes para interpretar medidas de tendencia central (la media queda muy influida por estos casos extremos).

```
===== Variable numérica: comment_count =====
count      537.000000
mean       7125.700186
std        36075.115032
min         0.000000
25%        1018.000000
50%        2354.000000
75%        5925.000000
max       810641.000000
Name: comment_count, dtype: float64
Nulos: 0
```





Figura 4: Visualización de comment_count

- **favorite_count.** Como se muestra la *Figura 5* esta variable presenta valores mínimos, máximos, media y desviación estándar iguales a cero, lo que indica que en la muestra no existe variación alguna: todos los videos muestran un conteo de favoritos igual a cero. Desde el punto de vista analítico, esta ausencia total de variabilidad implica que favorite_count no aporta información discriminante y puede descartarse en etapas posteriores de modelado o reducción de variables, dado que no ayuda a diferenciar entre videos.



```

===== Variable numérica: favorite_count =====
count      537.0
mean        0.0
std         0.0
min         0.0
25%         0.0
50%         0.0
75%         0.0
max         0.0
Name: favorite_count, dtype: float64
Nulos: 0

```



(a) Histograma y Densidad



(b) Boxplot

Figura 5: Visualización de favorite_count

- **engagement_rate.** Como se muestra la *Figura 6* la tasa de interacción global presenta una media aproximada de 0.0287, una mediana de 0.0244, un primer cuartil en torno a 0.0156 y un tercer cuartil cercano a 0.0374, con valores mínimos próximos a 0 y máximos alrededor de 0.2157. Esta distribución indica que, para la mayoría de los videos, la proporción combinada de interacciones respecto al número de vistas se sitúa entre 1.5 % y 3.7 %, pero existe un grupo pequeño de videos con tasas de interacción excepcionalmente altas (superiores al 20 %), que se destacan como posibles outliers positivos y señalan contenidos con una audiencia especialmente comprometida.

```

===== Variable numérica: engagement_rate =====
count      537.000000
mean        0.028722
std         0.020608
min         0.000000
25%         0.015579
50%         0.024368
75%         0.037366
max         0.215744
Name: engagement_rate, dtype: float64
Nulos: 0

```




Figura 6: Visualización de engagement_rate

- **likes_to_views_ratio.** Como se muestra la *Figura 7* la razón entre likes y vistas tiene una media de aproximadamente 0.0277, mediana de 0.0236 y un máximo cercano a 0.1991, con un rango intercuartílico que se extiende desde 0.0153 hasta 0.0363. Este patrón refleja que, en la mayoría de los casos, entre un 1.5 % y un 3.6 % de los espectadores presionan el botón de “me gusta”, mientras que unos pocos videos alcanzan proporciones extraordinariamente altas, lo cual sugiere un fuerte grado de afinidad o satisfacción del público con ese contenido específico.

```
===== Variable numérica: likes_to_views_ratio =====
count      537.000000
mean        0.027692
std         0.019708
min         0.000000
25%         0.015301
50%         0.023565
75%         0.036282
max         0.199095
Name: likes_to_views_ratio, dtype: float64
Nulos: 0
```





Figura 7: Visualización de likes_to_views_ratio

- **comments_to_views_ratio.** Como se muestra la *Figura 8* la razón comentarios/visitas presenta valores típicamente muy pequeños, con media de aproximadamente 0.0010, mediana cercana a 0.00040, un tercer cuartil alrededor de 0.00095 y un máximo de aproximadamente 0.0260. Esta estructura muestra que comentar es una acción mucho menos frecuente que dar “me gusta”, pero algunos videos consiguen tasas de comentario considerablemente más altas, lo que suele interpretarse como contenidos que generan discusión, controversia o una fuerte implicación emocional por parte de la audiencia.


```

===== Variable numérica: comments_to_views_ratio =====
count      537.000000
mean        0.001030
std         0.002166
min         0.000000
25%         0.000115
50%         0.000398
75%         0.000954
max         0.026031
Name: comments_to_views_ratio, dtype: float64
Nulos: 0

```



(a) Histograma y Densidad



(b) Boxplot


Figura 8: Visualización de comments_to_views_ratio

- **duration_seconds.** Como se muestra la *Figura 9* la duración en segundos exhibe una media cercana a 4,803 segundos, una mediana de 390 segundos (unos 6.5 minutos), un primer cuartil de 52 segundos, un tercer cuartil de 1,639 segundos y un máximo que supera los 105,000 segundos (casi 29 horas). Esta enorme dispersión indica que el conjunto incluye tanto videos extremadamente breves (posibles clips o formatos cortos) como contenidos muy extensos (por ejemplo, cursos completos o transmisiones largas), generando una distribución muy asimétrica hacia duraciones largas y sugiriendo que la variable podría beneficiarse de transformaciones (como escalas logarítmicas) para visualizarla y modelarla de manera más adecuada.


```

===== Variable numérica: duration_seconds =====
count      537.000000
mean       4802.746741
std        13748.249437
min         0.000000
25%        52.000000
50%        390.000000
75%       1639.000000
max       105227.000000
Name: duration_seconds, dtype: float64
Nulos: 0

```



(a) Histograma y Densidad



(b) Boxplot

Figura 9: Visualización de duration_seconds

- **video_age_days.** Como se muestra la *Figura 10* la antigüedad de los videos en días muestra una media aproximada de 934 días, con mediana de 658 días, un primer cuartil de 261 días, un tercer cuartil de 1,363 días, valores mínimos de 0 días y máximos cercanos a 4,772 días. Esta configuración sugiere que el conjunto mezcla videos muy recientes (incluidos contenidos de 0–1 días de antigüedad) con videos publicados hace varios años, lo que permite estudiar cómo la edad del contenido se relaciona con vistas y métricas de interacción, pero también indica una distribución sesgada hacia valores altos que conviene tener en cuenta al interpretar promedios y dispersión.

```

===== Variable numérica: video_age_days =====
count      537.000000
mean       934.050279
std        904.546132
min         0.000000
25%        261.000000
50%        658.000000
75%       1363.000000
max       4772.000000
Name: video_age_days, dtype: float64
Nulos: 0

```




Figura 10: Visualización de video_age_days

Categorico El análisis univariado de las variables categóricas del conjunto de datos se centra en describir la estructura de frecuencias de Title, channel_title, published_at, duration, definition y la propia category_id, entendida en este contexto como un identificador de categoría de contenido y no solo como un entero. El código correspondiente genera tablas de frecuencias absolutas y relativas, así como gráficos de barras (normalmente limitados a las categorías más frecuentes) con el propósito de identificar qué clases de contenido, formatos de calidad y características de accesibilidad predominan en las recomendaciones observadas. La salida generada por este comando se presenta en el Listing 3.

Listing 3: Ejecución Análisis Univariado (Categórica)

```

1  # Selección de columnas Categóricas
2  col_cat = df.select_dtypes(include=["object", "string", "category"]).
    columns.tolist()
3  if "Title" in col_cat:
4      col_cat.remove("Title") # excluimos Title por ser muy alta
        cardinalidad
5
6  for col in col_cat:
7      print(f"\n===== Variable categórica: {col} =====")
8      vc = df[col].value_counts(dropna=False)
9      print("Frecuencias absolutas:")
10     print(vc)
11     print("\nFrecuencias relativas (%):")
12     print((vc / len(df) * 100).round(2))
13
14     # Gráfico de barras (limitando a las 20 categorías más frecuentes para
        no saturar)
15     top_n = 20
16     plt.figure(figsize=(10, 4))
17     order = vc.head(top_n).index
18     sns.countplot(data=df, x=col, order=order)
19     plt.title(f"Distribución de {col} (top {top_n})")
20     plt.xlabel(col)
21     plt.ylabel("Cuenta")
22     plt.xticks(rotation=45, ha="right")
23     plt.tight_layout()
24     plt.show()

```

En el caso de **Title** y **channel_title**, se trata de variables de muy alta cardinalidad: prácticamente cada video tiene un título único y hay un número elevado de canales distintos, por lo que el análisis se orienta a detectar los canales más recurrentes y a describir la concentración de recomendaciones en torno a un conjunto reducido de productores de contenido. Al revisar las primeras filas del dataset se aprecia que aparecen tanto canales de entretenimiento masivo como creadores especializados en temas de programación, inteligencia artificial y aprendizaje automático, lo que sugiere que el sistema de recomendación combina contenido generalista de alta audiencia con contenido educativo y técnico de larga duración, como se muestra en la *Figura 11*.

```
===== Variable categórica: channel_title =====
```

```
Frecuencias absolutas:
```

```
channel_title
```

```
freeCodeCamp.org      22
```

```
Apna College          18
```

```
CodeWithHarry        12
```

```
AOA Review            9
```

```
Secret of yum         7
```

```
..
```

```
Shivin tutorial       1
```

```
Khris Sheer          1
```

```
Coder Coder          1
```

```
Thu Vu               1
```

```
NEXOS CREATOR        1
```

```
Name: count, Length: 344, dtype: int64
```

```
Frecuencias relativas (%):
```

```
channel_title
```

```
freeCodeCamp.org      4.10
```

```
Apna College          3.35
```

```
CodeWithHarry        2.23
```

```
AOA Review            1.68
```

```
Secret of yum         1.30
```

```
...
```

```
Shivin tutorial       0.19
```

```
Khris Sheer          0.19
```

```
Coder Coder          0.19
```

```
Thu Vu               0.19
```

```
NEXOS CREATOR        0.19
```

```
Name: count, Length: 344, dtype: float64
```




Figura 11: Distribución de channel_title

En el caso de **published_at**, como se muestra en la *Figura 12* el análisis de frecuencias muestra que los 537 videos tienen un instante de publicación único: cada marca de tiempo aparece exactamente una vez, con una frecuencia relativa aproximada de 0.19 %. Esto implica una cardinalidad extremadamente alta y, como variable categórica nominal, no aporta información estructural relevante más allá de confirmar que no hay duplicados exactos en el momento de publicación. Desde la perspectiva del análisis univariado, este comportamiento sugiere que **published_at** resulta mucho más útil si se transforma (por ejemplo, a fecha sin hora, día de la semana, franja horaria o antigüedad en días) y se analiza como variable temporal o numérica derivada, en lugar de tratar cada timestamp como una categoría independiente.




Figura 12: Distribución de published_at

===== Variable categórica: published_at =====

Frecuencias absolutas:

published_at

2025-08-24 16:00:39+00:00	1
2025-11-16 15:34:55+00:00	1
2025-11-17 17:00:47+00:00	1
2025-11-17 22:57:14+00:00	1
2025-11-17 09:00:07+00:00	1

..

2025-11-17 03:00:38+00:00	1
2025-11-07 06:58:26+00:00	1
2025-11-17 22:00:51+00:00	1
2025-11-17 17:01:35+00:00	1
2025-11-17 19:00:57+00:00	1

Name: count, Length: 537, dtype: int64

Frecuencias relativas (%):

published_at

2025-08-24 16:00:39+00:00	0.19
2025-11-16 15:34:55+00:00	0.19
2025-11-17 17:00:47+00:00	0.19
2025-11-17 22:57:14+00:00	0.19
2025-11-17 09:00:07+00:00	0.19

...

2025-11-17 03:00:38+00:00	0.19
2025-11-07 06:58:26+00:00	0.19
2025-11-17 22:00:51+00:00	0.19
2025-11-17 17:01:35+00:00	0.19
2025-11-17 19:00:57+00:00	0.19

Name: count, Length: 537, dtype: float64

En cuanto a duration, codificada en formato ISO 8601 (por ejemplo PT1M, PT59S, etc.), como se muestra en la *Figura 13* se identifican 366 duraciones distintas para los 537 videos, lo que indica también una alta diversidad de longitudes de contenido. No obstante, a diferencia de published_at, aquí sí se observan categorías recurrentes: la duración de 1 minuto (PT1M) concentra alrededor del 5.40 % de los videos, seguida por PT59S con un 3.17 % y varias duraciones muy cortas (entre 20 y 70 segundos) que aparecen con frecuencias cercanas al 1.30 %. Esta pauta refleja una clara concentración de recomendaciones en videos de formato breve (del orden de un minuto), típica de clips, avances y contenido altamente consumible, coexistiendo con una “cola larga” de duraciones menos frecuentes que incluyen videos de varios minutos u horas, lo que confirma que el sistema de recomendación mezcla contenido corto y largo en el mismo conjunto.

===== Variable categórica: duration =====

Frecuencias absolutas:

duration

PT1M	29
PT59S	17
PT1M1S	7
PT34S	7
PT20S	7

..

PT16M54S	1
PT1H3M21S	1
PT5H52M46S	1
PT5H55M47S	1
PT2M24S	1

Name: count, Length: 366, dtype: int64

Frecuencias relativas (%):

duration

PT1M	5.40
PT59S	3.17
PT1M1S	1.30
PT34S	1.30
PT20S	1.30

...

PT16M54S	0.19
PT1H3M21S	0.19
PT5H52M46S	0.19
PT5H55M47S	0.19
PT2M24S	0.19

Name: count, Length: 366, dtype: float64




Figura 13: Distribución de channel_title

La variable **definition** describe la calidad del video (por ejemplo, alta definición frente a definición estándar) y su distribución de frecuencias permite evaluar hasta qué punto el sistema de recomendación prioriza contenido en alta calidad visual. En las observaciones revisadas se observa un claro predominio de la categoría asociada a alta definición, con apariciones esporádicas de videos en definición estándar, lo que es coherente con las prácticas actuales de producción de contenido en la plataforma y señala que, en la muestra, la resolución rara vez actúa como factor limitante, como se muestra en la *Figura 14*.

===== Variable categórica: definition =====

Frecuencias absolutas:

definition

hd 535

sd 2

Name: count, dtype: int64

Frecuencias relativas (%):

definition

hd 99.63

sd 0.37

Name: count, dtype: float64




Figura 14: Distribución de definition

Finalmente, al tratar **category_id** como categórica y examinar su tabla de frecuencias y sus gráficos de barras (*Figura 1*), se identifican las categorías de contenido de YouTube que dominan las recomendaciones del conjunto analizado (por ejemplo, música, entretenimiento general o educación, dependiendo del mapeo oficial de categorías). La concentración de videos en unas pocas categorías revela los temas hacia los que está sesgado el sistema de recomendación en este subconjunto, y esta información resulta clave para interpretar los patrones de vistas e interacción observados en el análisis numérico, al conectar la popularidad con el tipo de contenido al que pertenece cada video.

3.1.3. Limpieza y transformación de datos

El primer paso consistió en definir un subconjunto de variables numéricas continuas relevantes para el análisis, tales como el conteo de vistas, el conteo de “me gusta”, el conteo de comentarios, las razones de interacción y la duración de los videos en segundos. Estas variables presentan escalas diferentes y, en muchos casos, distribuciones marcadamente asimétricas debido a la naturaleza de los datos de popularidad en plataformas digitales, donde una pequeña proporción de videos concentra la mayoría de las vistas e interacciones. La selección de estas variables numéricas permite aplicar métodos estadísticos específicos para atenuar la influencia de valores extremos y corregir el sesgo de las distribuciones antes de construir modelos predictivos o descriptivos más avanzados. La salida generada por este comando se presenta en el Listing 4.

Listing 4: Limpieza y transformación de datos

```
1 from scipy import stats
2 from sklearn.preprocessing import PowerTransformer
3
4 # 1. Selección de variables numéricas continuas
5 num_cols = [
6     "view_count",
7     "like_count",
8     "comment_count",
9     "engagement_rate",
```

```
10     "likes_to_views_ratio",
11     "comments_to_views_ratio",
12     "duration_seconds",
13     "video_age_days"
14 ]
15
16 # 2. Tratamiento de outliers con z-score truncado
17 def winsorize_zscore(series, z_thresh=3.0):
18     z = np.abs(stats.zscore(series.replace([np.inf, -np.inf], np.nan).
19         dropna()))
19     s = series.copy()
20     # límites superior e inferior con base en percentiles "sanos"
21     lower = series[(z < z_thresh)].quantile(0.01)
22     upper = series[(z < z_thresh)].quantile(0.99)
23     return np.clip(s, lower, upper)
24
25 for col in num_cols:
26     df[col] = winsorize_zscore(df[col])
27
28 # 3. Corrección de sesgo (skewness) con transformación Yeo-Johnson
29 pt = PowerTransformer(method="yeo-johnson", standardize=False)
30 df[num_cols] = pt.fit_transform(df[num_cols])
31
32 df.head()
```

Para reducir el impacto de los valores atípicos se utilizó un procedimiento de tipo *winsorización* basada en la puntuación *z-score*. Este enfoque calcula la desviación estandarizada de cada observación respecto a la media, lo que facilita identificar observaciones alejadas más de un umbral predefinido, en este caso tres desviaciones estándar. En lugar de eliminar por completo estos registros, que podrían contener información útil, se ajustaron sus valores extremos recortándolos a percentiles internos (por ejemplo, del 1 al 99). Este método conserva el tamaño muestral y limita el efecto de valores extremos sobre estadísticas como la media y la varianza, mejorando la estabilidad de los modelos posteriores. La winsorización es especialmente adecuada en contextos donde los outliers reflejan comportamientos reales pero poco frecuentes, como videos extraordinariamente virales.

Una vez mitigado el efecto de los outliers, se abordó el problema del sesgo en las distribuciones de las variables numéricas. Para ello se empleó la transformación de Yeo-Johnson, que es una extensión de la familia de transformaciones de potencia y tiene la ventaja de admitir valores negativos y ceros, a diferencia de la transformación clásica de Box-Cox. Este método estima un parámetro de potencia para cada variable, con el objetivo de aproximar la normalidad y reducir la asimetría. La corrección del sesgo contribuye a mejorar el cumplimiento de supuestos de normalidad en diversos modelos estadísticos y algoritmos de aprendizaje automático sensibles a la forma de la distribución, como los métodos basados en distancias o que asumen errores aproximadamente gaussianos. Además, una distribución más simétrica tiende a producir coeficientes y métricas más interpretables y comparables entre variables.

En la implementación práctica se ajustó el transformador de Yeo-Johnson sobre el conjunto de columnas numéricas ya depuradas y se aplicó la transformación sin estandarizar las variables de manera inmediata. La decisión de no estandarizar en este punto permite separar conceptualmente la corrección del sesgo de la posterior normalización de escala, que se ejecuta dentro de la etapa

de preprocesamiento para modelado. Los parámetros de la transformación, denominados λ , se almacenaron para cada característica con el fin de asegurar la reproducibilidad del procedimiento, de manera que las mismas transformaciones puedan aplicarse a nuevos datos en fases de validación o despliegue de modelos.

3.1.4. Codificación y estandarización

Para integrar de manera coherente variables numéricas y categóricas en un mismo conjunto de características se diseñó un esquema de preprocesamiento basado en transformaciones diferenciadas. Las variables numéricas transformadas se asignaron a un flujo de procesamiento que aplica estandarización, mientras que las variables categóricas (por ejemplo, identificadores de categoría, resolución del video, presencia de subtítulos o nombre del canal) se asignaron a un flujo de codificación mediante variables indicadoras. Esta separación permite tratar adecuadamente la naturaleza de cada tipo de dato y minimizar la pérdida de información relevante durante la preparación del conjunto de entrenamiento. La salida generada por este comando se presenta en el Listing 5.

Listing 5: Codificación y estandarización

```
1  # ===Codificación===
2  from sklearn.preprocessing import OneHotEncoder, StandardScaler
3  from sklearn.compose import ColumnTransformer
4  from sklearn.pipeline import Pipeline
5
6  # Preprocesador: One-Hot para categóricas, estándar para numéricas
7  numeric_transformer = Pipeline(steps=[
8      ("scaler", StandardScaler())])
9
10 categorical_transformer = Pipeline(steps=[
11     ("onehot", OneHotEncoder(handle_unknown="ignore", sparse_output=False)
12     )])
13
14 preprocessor = ColumnTransformer(
15     transformers=[
16         ("num", numeric_transformer, cat_num),
17         ("cat", categorical_transformer, cat_vars)])
18
19 # ===Estandarización===
20 # Ajuste y transformación
21 X = df[cat_num + cat_vars].copy()
22 X_preprocessed = preprocessor.fit_transform(X)
23
24 # 4. Obtener nombres de columnas resultantes (útil para análisis posterior
25 )
26 num_feature_names = cat_num
27 cat_feature_names = preprocessor.named_transformers_["cat"]["onehot"].
28     get_feature_names_out(cat_vars)
29 feature_names = np.concatenate([num_feature_names, cat_feature_names])
30
31 df_model = pd.DataFrame(X_preprocessed, columns=feature_names, index=df.
32     index)
33 df_model.head()
```

En el caso de las variables categóricas se utilizó la codificación *one-hot*, que crea una columna binaria por cada categoría observada en el conjunto de datos. Este método evita imponer un orden artificial sobre las categorías y resulta adecuado para algoritmos lineales y muchos modelos de aprendizaje automático que requieren entradas numéricas. Adicionalmente, se activó el manejo de categorías desconocidas, de forma que cualquier categoría nueva en datos futuros se gestione sin producir errores, asignándola a un patrón de ceros. La codificación *one-hot* puede incrementar la dimensionalidad del conjunto de datos, pero ofrece interpretabilidad y compatibilidad amplias con distintos algoritmos.

Para las variables numéricas se aplicó una estandarización mediante la transformación de *z-score*, restando la media y dividiendo entre la desviación estándar de cada variable. Este proceso produce características con media aproximadamente cero y varianza unitaria, lo cual resulta fundamental para modelos sensibles a la escala, como la regresión logística, las máquinas de vectores de soporte o los métodos basados en distancia euclidiana. La estandarización complementa la corrección previa del sesgo, de modo que las características suministradas a los modelos se encuentran tanto en una escala comparable como con distribuciones menos asimétricas. Este diseño contribuye a una mejor convergencia de los algoritmos de optimización y reduce el riesgo de que variables con magnitudes mayores dominen el proceso de aprendizaje.

La combinación de ambas familias de transformaciones se implementó mediante un transformador de columnas que integra, en una sola estructura, tanto el escalador para las variables numéricas como el codificador para las categóricas. Esta arquitectura facilita la construcción de *pipelines* de modelado reproducibles, en los que las mismas transformaciones se aplican de forma coherente durante el entrenamiento, la validación y la fase de inferencia. Además, el uso de un esquema declarativo para las columnas numéricas y categóricas facilita la actualización del flujo de trabajo cuando se incorporan nuevas variables o se modifican las existentes, manteniendo la trazabilidad del proceso de preprocesamiento.

3.2. Parte II

3.2.1. Método: Correlación Canónica

El conjunto de datos analizado contiene múltiples variables cuantitativas que describen el desempeño de videos en una plataforma digital, incluyendo el conteo de vistas, el conteo de “me gusta”, el conteo de comentarios, la duración del video y la antigüedad en días, así como indicadores relativos de eficiencia como la tasa de interacción (*engagement rate*) y las razones de “me gusta” y comentarios respecto a las vistas totales. Estas variables se pueden agrupar de forma natural en dos bloques: un bloque de escala o alcance del contenido, que captura el tamaño absoluto de la audiencia, y un bloque de eficiencia o comportamiento relativo de la audiencia, que mide cuánta interacción se genera en proporción a la exposición del video [8], [3].

Para estudiar la relación multivariada entre estos dos bloques se aplicó el método de correlación canónica. La correlación canónica busca combinaciones lineales de cada conjunto de variables de forma que la correlación entre dichas combinaciones sea máxima, produciendo pares de variables canónicas que resumen el patrón de asociación entre ambos bloques [4], [3]. En este contexto, el primer conjunto de combinaciones resume el patrón de variación conjunta en las variables de escala del video, mientras que el segundo conjunto resume el patrón de variación en los indicadores de eficiencia, permitiendo cuantificar qué tanto se relacionan los cambios en el tamaño o alcance

del video con cambios en el comportamiento relativo de la audiencia.

En la implementación se definió el bloque X con las variables de escala: conteo de vistas, conteo de “me gusta”, conteo de comentarios, duración en segundos y antigüedad del video. El bloque Y se definió con las variables de eficiencia: tasa de interacción, razón de “me gusta” sobre vistas y razón de comentarios sobre vistas. Previamente, las variables habían sido sometidas a un proceso de limpieza, corrección de sesgo y estandarización para aproximar mejor los supuestos de linealidad y normalidad multivariante típicamente asumidos por la correlación canónica [5]. Posteriormente, se ajustó un modelo de correlación canónica con tantas componentes como permitía el tamaño de los bloques (es decir, el mínimo entre el número de variables de escala y el número de variables de eficiencia), y se obtuvieron tanto las correlaciones canónicas como las cargas de las variables originales sobre las variables canónicas.

La salida generada por este comando se presenta en el Listing 6.

Listing 6: Correlación Canónica

```

1 from sklearn.cross_decomposition import CCA
2 from sklearn.preprocessing import StandardScaler
3
4 # 1. Definir bloques de variables
5 # Bloque X: variables de "escala/alcance" del video
6 X_cols = [
7     "view_count",
8     "like_count",
9     "comment_count",
10    "duration_seconds",
11    "video_age_days"]
12
13 # Bloque Y: variables de "eficiencia/engagement"
14 Y_cols = [
15     "engagement_rate",
16     "likes_to_views_ratio",
17     "comments_to_views_ratio"]
18
19 # 2. Construir matrices X e Y
20 X = df_model[X_cols].values
21 Y = df_model[Y_cols].values
22
23 # 3. Ajustar CCA con k componentes canónicas
24 n_components = min(len(X_cols), len(Y_cols))
25 cca = CCA(n_components=n_components)
26
27 X_c, Y_c = cca.fit_transform(X, Y)
28
29 # 4. Correlaciones canónicas
30 corrs = []
31 for i in range(n_components):
32     corr = np.corrcoef(X_c[:, i], Y_c[:, i])[0, 1]
33     corrs.append(corr)
34
35 corrs = np.array(corrs)
36
37 # 5. Cargarings (correlaciones entre variables originales y variables canó
    nicas)

```

```

38 loadings_X = np.corrcoef(X.T, X_c.T)[0:len(X_cols), len(X_cols):]
39 loadings_Y = np.corrcoef(Y.T, Y_c.T)[0:len(Y_cols), len(Y_cols):]
40
41 loadings_X_df = pd.DataFrame(
42     loadings_X,
43     index=X_cols,
44     columns=[f"U{i+1}" for i in range(n_components)])
45
46 loadings_Y_df = pd.DataFrame(
47     loadings_Y,
48     index=Y_cols,
49     columns=[f"V{i+1}" for i in range(n_components)])
50
51 # 6. DataFrame con correlaciones canónicas
52 cca_results = pd.DataFrame({
53     "Componente": [f"Par {i+1}" for i in range(n_components)],
54     "Correlacion_canonica": corrs})
55
56 print("Correlaciones canónicas:")
57 print(cca_results)
58
59 print("\nLoadings de X (variables originales vs U):")
60 print(loadings_X_df)
61
62 print("\nLoadings de Y (variables originales vs V):")
63 print(loadings_Y_df)

```

El código se estructura en varias etapas que corresponden a la lógica del método de correlación canónica. En primer lugar, se seleccionan explícitamente las columnas numéricas que conforman cada bloque y se extraen en dos matrices, X y Y , asegurando que cada fila represente al mismo video en ambos bloques. A continuación, se aplica una estandarización independiente a cada bloque, restando la media y dividiendo por la desviación estándar de cada variable. Esta estandarización es importante porque la correlación canónica se basa en la estructura de covarianzas y correlaciones, y la presencia de escalas muy diferentes puede distorsionar las combinaciones lineales que el algoritmo obtiene [9], [8].

En segundo lugar, se ajusta el modelo de correlación canónica especificando el número de componentes, que corresponde al número de pares de variables canónicas que se desean calcular. Este número se fija como el mínimo entre la cantidad de variables del bloque X y del bloque Y , de modo que el problema esté bien definido. El modelo aprende matrices de pesos para cada bloque que generan nuevas variables canónicas como combinaciones lineales de las variables estandarizadas. El resultado directo de este ajuste son las matrices de puntuaciones canónicas para cada observación, que representan los valores de las variables canónicas en cada par.

En tercer lugar, el código calcula las correlaciones entre las variables canónicas correspondientes a cada par, generando así las correlaciones canónicas. Estas correlaciones cuantifican la fuerza de la relación lineal entre las combinaciones de variables de escala y las combinaciones de variables de eficiencia. Adicionalmente, se estiman las cargas (*loadings*) de las variables originales respecto a las variables canónicas, calculando las correlaciones entre las columnas estandarizadas de X y las variables canónicas del primer bloque, y de manera análoga entre las columnas de Y y las variables canónicas del segundo bloque [7]. Estas cargas facilitan la interpretación de qué variables

contribuyen más a cada dimensión canónica de la relación entre escala y eficiencia del contenido.

3.2.2. Justificación

La elección de la correlación canónica se justifica por la presencia de dos conjuntos de variables conceptualmente diferenciados pero medidos sobre las mismas unidades de análisis. Por un lado, existe un conjunto de indicadores de escala que describe el nivel absoluto de exposición de los videos, mientras que por otro lado, existe un conjunto de indicadores de eficiencia que describe el comportamiento relativo de la audiencia. El interés analítico se centra en comprender cómo se relacionan estos dos bloques de forma conjunta, más allá de correlaciones simples entre pares de variables individuales. La correlación canónica fue desarrollada específicamente para estudiar la asociación entre dos conjuntos multivariantes, generalizando la idea de correlación de Pearson a un contexto de múltiples variables dependientes e independientes [4], [6].

A diferencia de métodos como el análisis de regresión múltiple, que modelan un conjunto de variables dependientes a partir de un conjunto de predictores, la correlación canónica trata los dos bloques de manera simétrica y busca combinaciones lineales en ambos que maximicen la correlación mutua [8]. Esta simetría es adecuada en el presente problema, dado que ni el bloque de escala ni el de eficiencia se considera estrictamente como dependiente del otro, sino que se pretende explorar su relación conjunta. Frente al análisis factorial o el análisis de componentes principales, que se aplican a un único conjunto de variables, la correlación canónica conserva la identidad de cada bloque y produce funciones canónicas que se interpretan como dimensiones latentes de asociación entre la escala del contenido y la eficiencia de la interacción de la audiencia [7].

Entre las alternativas mencionadas, el análisis de correspondencias se orienta principalmente a tablas de contingencia y variables categóricas, por lo que resulta menos adecuado para un conjunto de datos predominantemente cuantitativo como el considerado. Las ecuaciones estructurales requieren una especificación previa de un modelo causal detallado con variables latentes y relaciones direccionales, algo que excede el alcance exploratorio de este ejercicio. El análisis conjoint, por su parte, se aplica típicamente a estudios de preferencias individuales sobre perfiles de productos diseñados experimentalmente, un contexto distinto al análisis de desempeño de videos en una plataforma digital. En contraste, la correlación canónica se ajusta de manera directa a la estructura y al objetivo del dataset, permitiendo un análisis exploratorio multivariado robusto de la relación entre escala y eficiencia del contenido.

3.2.3. Utilidad del método “Correlación Canónica” en el dataset

La aplicación de la correlación canónica al dataset proporciona varias utilidades prácticas y conceptuales. En primer lugar, permite reducir la complejidad de la relación entre múltiples métricas de desempeño a un número limitado de dimensiones canónicas que resumen el patrón dominante de asociación entre la escala del video y la eficiencia de la interacción. Estas dimensiones pueden interpretarse como factores latentes que sintetizan cómo evoluciona el comportamiento de la audiencia a medida que cambian las magnitudes de vistas, “me gusta”, comentarios, duración y antigüedad del contenido. Esta reducción dimensional facilita la comunicación de resultados y puede servir como insumo para modelos posteriores que utilicen como variables de entrada las puntuaciones canónicas en lugar de todas las variables originales [8], [7].

En segundo lugar, las cargas de las variables originales sobre cada función canónica permiten identificar qué métricas de escala y de eficiencia son más influyentes en las relaciones encontradas. Por ejemplo, una función canónica podría estar dominada por el conteo de vistas y la razón de “me gusta” sobre vistas, lo que sugeriría que determinados patrones de crecimiento en el alcance del video se asocian estrechamente con cambios en la intensidad relativa de aprobación de la audiencia. Esta información puede ser útil para la toma de decisiones de contenido, como priorizar métricas específicas en la evaluación de campañas o ajustar estrategias de publicación y duración de los videos.

En tercer lugar, las correlaciones canónicas y los índices derivados, como la redundancia, pueden emplearse para evaluar qué proporción de la variabilidad en un bloque de variables puede explicarse por el otro bloque a través de las combinaciones lineales obtenidas [7], [10]. Este enfoque permite responder preguntas como hasta qué punto las diferencias en el comportamiento relativo de interacción se asocian con cambios en el tamaño y antigüedad de los videos, o si existen dimensiones de eficiencia que son relativamente independientes del alcance. Desde una perspectiva metodológica, el uso de correlación canónica en este contexto también ofrece un ejemplo concreto de cómo las técnicas multivariantes clásicas pueden aportar valor en el análisis de datos de plataformas digitales contemporáneas.

3.2.4. Análisis de los resultados

Correlaciones canónicas:

	Componente	Correlacion_canonica
0	Par 1	0.929982
1	Par 2	0.812982
2	Par 3	0.246385

Loadings de X (variables originales vs U):

	U1	U2	U3
view_count	0.600850	-0.047081	-0.178493
like_count	0.335180	0.526773	-0.050740
comment_count	-0.426414	-0.193885	-0.081570
duration_seconds	-0.426191	-0.429690	0.674261
video_age_days	0.237614	-0.144068	0.753019

Loadings de Y (variables originales vs V):

	V1	V2	V3
engagement_rate	-0.538238	0.842792	0.001533
likes_to_views_ratio	-0.486255	0.871526	0.063237
comments_to_views_ratio	-0.984760	-0.169300	-0.039820

Los resultados de la correlación canónica muestran tres pares de variables canónicas, con correlaciones canónicas aproximadas de 0.93 para el primer par, 0.81 para el segundo y 0.25 para el tercero. Estas cifras indican que las dos primeras funciones canónicas capturan relaciones lineales muy fuertes entre el bloque de variables de escala del video y el bloque de variables de eficiencia, mientras que la tercera función canónica representa una asociación mucho más débil y probablemente de menor relevancia práctica [8], [7]. En términos generales, el análisis sugiere que

gran parte de la relación entre ambos conjuntos de variables puede resumirse en dos dimensiones latentes principales.

En el primer conjunto de cargas canónicas para el bloque de escala (U1), la variable *view_count* presenta una carga positiva relativamente alta, mientras que *comment_count* y *duration_seconds* exhiben cargas negativas de magnitud moderada. Esto sugiere que la primera función canónica de escala está asociada a un contraste entre videos con un alto número de vistas y menor duración o menor conteo de comentarios, frente a videos con más comentarios o mayor duración pero relativamente menos vistas. La variable *video_age_days* también muestra una carga positiva, aunque de menor magnitud, lo que indica que la antigüedad del video contribuye en cierta medida a esta dimensión, posiblemente reflejando que los videos con más tiempo en la plataforma tienden a acumular más vistas.

En el primer conjunto de cargas canónicas para el bloque de eficiencia (V1), la variable *comments_to_views_ratio* presenta una carga negativa muy alta, mientras que *engagement_rate* y *likes_to_views_ratio* también muestran cargas negativas de magnitud considerable. Esta configuración implica que la primera función canónica de eficiencia captura principalmente un patrón donde las razones de interacción, en particular la proporción de comentarios respecto a las vistas, varían en oposición al patrón de escala descrito por U1. Dado que la correlación canónica entre U1 y V1 es positiva y muy alta, se puede interpretar que a medida que aumenta la combinación lineal de escala asociada a mayores vistas y cierto perfil de duración y comentarios, disminuye la intensidad relativa de interacción, especialmente en términos de comentarios por vista.

El segundo par de funciones canónicas, con una correlación canónica todavía elevada, alrededor de 0.81, también aporta información relevante sobre la relación entre escala y eficiencia. En este caso, las cargas de *like_count* y *duration_seconds* en U2 son positivas y relativamente altas, mientras que otras variables de escala presentan cargas de menor magnitud. Esto sugiere que la segunda dimensión de escala está más relacionada con la combinación de duración del video y número de “me gusta”. Por el lado de la eficiencia, la segunda función canónica (V2) muestra cargas positivas muy altas tanto en *engagement_rate* como en *likes_to_views_ratio*, lo que indica que esta dimensión captura variaciones conjuntas en la intensidad global de interacción y en la proporción de “me gusta” por vista. La fuerte correlación entre U2 y V2 sugiere que existe una dimensión en la que videos con ciertas combinaciones de duración y volumen de “me gusta” se asocian con niveles más altos de eficiencia en términos de engagement y aprobación relativa de la audiencia.

El tercer par de funciones canónicas presenta una correlación mucho menor, en torno a 0.25, lo que implica que la relación lineal entre las combinaciones correspondientes de escala y eficiencia es débil. En este nivel, las cargas de *duration_seconds* y *video_age_days* son positivas y elevadas en U3, mientras que las variables de eficiencia muestran cargas de baja magnitud en V3. Esta configuración sugiere que la tercera dimensión refleja principalmente variaciones internas dentro del bloque de escala, relacionadas con la duración y antigüedad de los videos, que no se traducen en cambios claros en las medidas de eficiencia. Desde un punto de vista práctico, esta función canónica puede considerarse de menor importancia para la interpretación, ya que aporta poca información adicional sobre la relación entre escala y eficiencia [3], [10].

En conjunto, el patrón de correlaciones canónicas y cargas indica que la relación entre el tamaño del desempeño de los videos y la eficiencia de interacción de la audiencia puede resumirse de forma efectiva mediante dos dimensiones principales. La primera dimensión se asocia con un contraste entre alto volumen de vistas y menor intensidad relativa de comentarios, mientras que

la segunda dimensión vincula la combinación de duración y cantidad de “me gusta” con niveles más altos de engagement y aprobación por vista. Estas interpretaciones pueden orientar decisiones sobre diseño de contenido, duración óptima y objetivos de interacción, así como servir de base para segmentaciones posteriores o modelos predictivos que utilicen las puntuaciones canónicas como variables latentes representativas del comportamiento de los videos en la plataforma.

4. Conclusión

La aplicación conjunta de procedimientos de limpieza, transformación, codificación y estandarización de datos, seguida de un análisis de correlación canónica, permite obtener una comprensión más profunda del desempeño de los videos en términos de escala y eficiencia de interacción. La winsorización y las transformaciones de potencia contribuyen a mitigar los efectos de valores atípicos y distribuciones sesgadas, mientras que la codificación adecuada de variables categóricas y la estandarización de las numéricas garantizan que las diferentes características puedan integrarse coherentemente en modelos multivariantes [11], [12], [13]. Sobre esta base, la correlación canónica extrae funciones canónicas que sintetizan la relación entre ambos bloques de variables, identificando dimensiones latentes que reflejan cómo se asocian el alcance de los videos y los indicadores de engagement relativo [4], [3], [7].

Los resultados obtenidos muestran que un número reducido de funciones canónicas es capaz de capturar una proporción sustancial de la relación entre las métricas de escala y las de eficiencia, lo cual facilita la interpretación y la toma de decisiones basada en evidencia. Estas dimensiones latentes pueden emplearse tanto para describir patrones de comportamiento de la audiencia como para servir de insumo en modelos predictivos y estrategias de optimización de contenido. En conjunto, el enfoque seguido en este trabajo ilustra cómo las técnicas de estadística multivariante clásica, apoyadas en un preprocesamiento riguroso de los datos, ofrecen herramientas poderosas para el análisis de información generada por plataformas digitales contemporáneas.

Referencias

- [1] Shahid, S. (2025). *YouTube Analytics Data* [Data set]. Kaggle. <https://www.kaggle.com/datasets/shaistashahid/youtube-analytics-data>
- [2] IBM. (2021). *What is Exploratory Data Analysis?* IBM Think. <https://www.ibm.com/think/topics/exploratory-data-analysis>
- [3] Bykhovskaya, A., & Gorin, V. (2024). Canonical correlation analysis: Review. *arXiv*. <https://arxiv.org/abs/2411.15625>
- [4] Hotelling, H. (1936). Relations between two sets of variates. *Biometrika*, 28(3/4), 321–377.
- [5] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer.
- [6] Knapp, T. R. (2019). Canonical correlation analysis: A general parametric significance-testing system. *Journal of Modern Applied Statistical Methods*, 18(2), eP3185.
- [7] MVStats. (2022). *Canonical correlation analysis*. MVStats. <https://mvstats.com>
- [8] Pennsylvania State University. (s.f.). *Lesson 13: Canonical correlation analysis*. STAT 505 – Applied multivariate statistical analysis. Department of Statistics, Penn State. <https://online.stat.psu.edu/stat505>
- [9] StatSoft. (1997). *Canonical correlation*. StatSoft Electronic Textbook. <https://www.statsoft.com>
- [10] Statistics Solutions. (2025). *Conduct and interpret a canonical correlation*. Statistics Solutions. <https://www.statisticssolutions.com>
- [11] Box, G. E. P., & Cox, D. R. (1964). An analysis of transformations. *Journal of the Royal Statistical Society: Series B (Methodological)*, 26(2), 211–252.
- [12] Yeo, I.-K., & Johnson, R. A. (2000). A new family of power transformations to improve normality or symmetry. *Biometrika*, 87(4), 954–959.
- [13] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer.